

# 人工智能导论： 对抗性的搜索 (Adversarial Search)

---

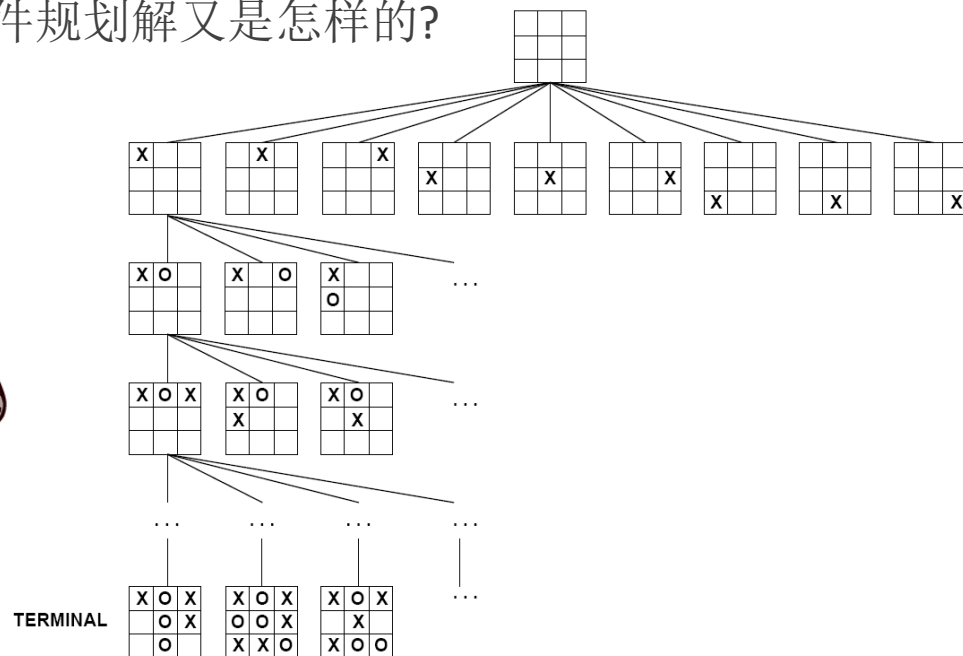

齐琦

海南大学

# 井字游戏

如何用与或搜索（AND-OR search）来求解井字游戏？


- 如果你想赢得这个游戏，你的条件规划解是怎样的？
- 如果你想至少打平这个游戏，那么条件规划解又是怎样的？



# 内容提纲

---

- 历史和展望
- 零和游戏 (最小最大值)
- 评估函数
- 搜索效率 ( $\alpha$ - $\beta$  剪枝)
- 机遇博弈 (期望最大值)



# 计算机游戏/比赛的当前水平

---

## 国际跳棋

- 1950年，第一个计算机跳棋程序
- 1994年，计算机击败人类冠军(Marion Tinsley)
- 2007年，游戏搜索问题被解决。总共有39万亿个终局状态

## 国际象棋

- 1945-1960年，计算机国际象棋程序
- 1997年，象棋机器深蓝击败人类冠军


## 围棋

- 1968年，计算机围棋程序出现
- 2005-2014年，蒙特卡罗树搜索提高了程序性能；当前水平能击败高水平的业余选手，和部分职业选手

## 吃豆子 (Pacman)


# 人工智能的博弈水平

---



# 视屏展示：神秘的Pacman智能体

---




# 游戏类型

---

## 描述角度

- 环境变换确定的，或不确定的？
- 信息完全可观察的？
- 一个，两个，或多个玩家？
- 轮流，或是即时的？
- 零和的？

算法的目的是计算一个依情况而定的行动计划（策略），为每一个可能的事件推荐一个相应的行动。




# 人工智能所研究的“标准的” 游戏比赛（games）

---

标准的游戏是，确定的，全局可观察的，轮流行动的，两人的，零和的。


游戏问题的模型建立：

- 初始状态:  $s_0$
- 玩家:  $\text{Player}(s)$  显示在当前状态轮到哪一个玩家行动
- 行动:  $\text{Actions}(s)$  当前轮次的玩家可能的移动
- 状态转换模型:  $\text{Result}(s,a)$
- 终局状态检测:  $\text{Terminal-Test}(s)$  是否是终局
- 终局得分:  $\text{Utility}(s,p)$  玩家  $p$  的得分
  - 或只用  $\text{Utility}(s)$  代表游戏一开始时首先移动的玩家的分






# 零和游戏，以及和通常游戏的区别



## 零和游戏

- 智能体**竞争**实现**相反的**利益
- 一方**最大化**这个**利益**, 另一方**最小化**它




## 通常游戏


- 智能体有**独立的**利益
- 合作, 竞争, 联盟等相互关系, 都有可能

# 对抗性搜索

---

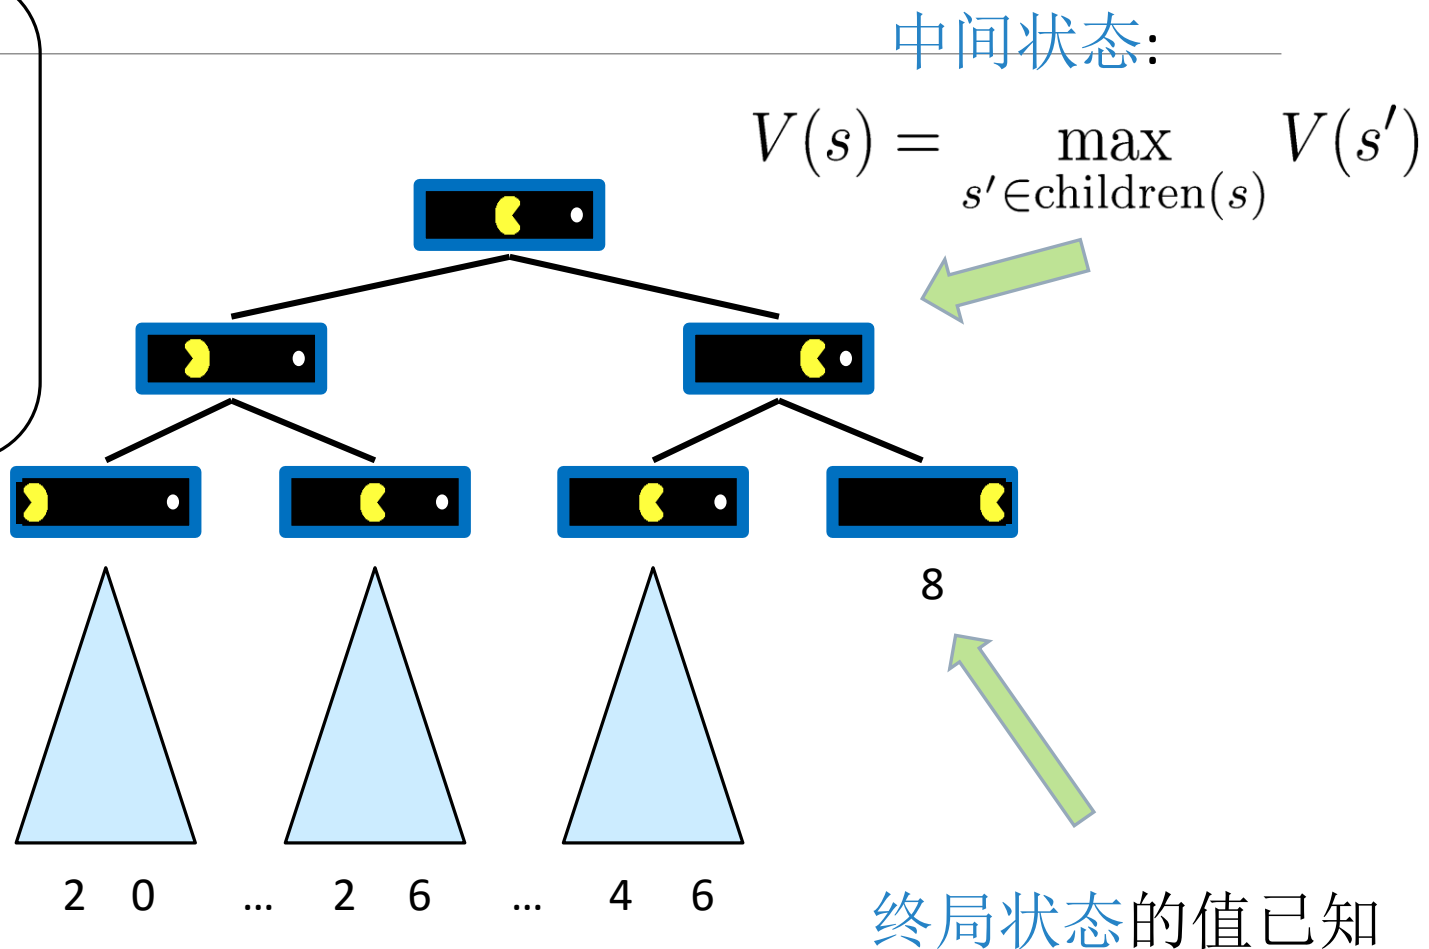


# 单一智能体搜索树




# 状态值（中间和终局状态值）

一个状态的值：从这个状态往下走可能达到的最大利益值（结果）



# 井字游戏搜索树




# 最小最大值（Minimax values）

MAX 节点: 智能体控制下的节点状态

$$V(s) = \max_{s' \in \text{successors}(s)} V(s')$$

MIN 节点: 对手控制下的节点状态

$$V(s') = \min_{s \in \text{successors}(s')} V(s)$$



终局状态的值是已知的

# 最小最大算法(Minimax) 实现

深度优先搜索

Function 最小最大-决策(s) returns 一个行动

return 行动 a in Actions(s), 它能导致最大的  
最小-值(Result(s,a))的返回值

Function 最大-值(s) returns 一个值

If 终局-检测(s) then return Utility(s)

初始化  $v = -\infty$

for each a in Actions(s):

$v = \max(v, \text{最小-值}(\text{Result}(s,a)))$

return v

Function 最小-值(s) returns 一个值

If 终局-检测(s) then return Utility(s)

初始化  $v = +\infty$

for each a in Actions(s):

$v = \min(v, \text{最大-值}(\text{Result}(s,a)))$

return v

$$V(s) = \max_{s' \in \text{successors}(s)} V(s')$$

$$V(s') = \min_{s \in \text{successors}(s')} V(s)$$

# 另一种实现方法

Function 最小最大-决策(s) returns 一个行动

return 行动  $a$  in  $\text{Actions}(s)$  , 它能导致最大的  
 $\text{value}(\text{Result}(s,a))$  的返回值



function  $\text{value}(s)$  returns 一个值

If 终局-检测(s) then return  $\text{Utility}(s)$


if  $\text{Player}(s) = \text{MAX}$  then return  $\max_{a \in \text{Actions}(s)} \text{value}(\text{Result}(s,a))$

if  $\text{Player}(s) = \text{MIN}$  then return  $\min_{a \in \text{Actions}(s)} \text{value}(\text{Result}(s,a))$



# 最小最大值（Minimax）举例

---




# Minimax 的效率

## Minimax 的效率?

- 深度优先穷尽搜索
- 时间复杂度:  $O(b^m)$
- 空间复杂度:  $O(bm)$

举例: 国际象棋, ,  $b \approx 35$ ,  $m \approx 100$

- 找到准确解, 不可行
- 有必要探索整棵树吗? 人是如何下象棋的, 是如何思考的?



# 资源有限 vs 庞大的搜索空间

---



# 资源局限

问题: 现实中, 几乎不能搜索到叶节点!

办法之一: 有界搜索加预测


- 搜索只到预定深度层次
- 使用 **评估函数** 预测搜索边界节点的值

失去了最优解的保证

搜索的层次越多结果就越不相同

例如:

- 假设计算时间有**100** 秒, 每秒能探索1万个节点
- 所以每步能检查**1**百万个节点
- 在国际象棋中,  $b \sim 35$  , 搜索大致能达到搜索树的第4层  
– 还是不够好




# 探索深度的重要性

- 评估函数总是不完美的  
(不准确的)
- 通常, 越深的搜索 => 越好的表现
- 或者说, 更深的搜索能够弥补相对不准确的评估函数
- 评估函数设计复杂度和计算复杂度之间的权衡




# 视屏演示：有限搜索深度 (深度=2)

---



# 视屏演示：有限搜索深度 (深度=10)

---



# 评估函数


---





# 评估函数

在一个限定深度搜索中，用来给非终局节点状态估值。




理想函数: 返回这个节点状态的实际最小最大值

实践中: 特征函数值的加权线性组合:

- $EVAL(s) = w_1 f_1(s) + w_2 f_2(s) + \dots + w_n f_n(s)$
- 例如  $w_1 = 9$ ,  $f_1(s) = (\text{白皇后数量} - \text{黑皇后数量})$ , 等。

评估函数应作用在 **沉寂** 状态节点, 即其后继状态的评估值相对变化不大。


# Pacman游戏状态评估




评估函数值应反映所处的局面。

# 评估函数实例演示：犹豫的情况 (深度=2)

---



# Pacman 为什么会犹豫？




智能体重新规划可能面临的处境

- 在当前两步搜索的情况下，向左吃掉豆子的得分和向右移动的是一样的（后面可能会吃掉豆子）
- 得分是用最小最大值方法得到的
- 所以这个时候等待和吃掉豆子的选择结果似乎一样；它有可能向右移动，然后下一轮重新规划时，可能又走回来了！


# 调整评估函数，解决这个问题 (深度=2)

---



# 演示：共同的评估函数可自动形成合作

---





# 普遍化的最小最大值法 (minimax)

如果不是零和游戏，或有多多个玩家？


普遍情况：

- 终局（叶结点）的值是一组值
- 中间状态节点的值也是一组值
- **每个玩家最大化自己的利益值**
- 能够动态产生协作和竞争等关系...



# 博弈（游戏）树的剪枝 (Game Tree Pruning)


---






# 最小最大法举例

---



# Alpha-Beta 剪枝例子


$\alpha$  = 在当前路径上所有MAX节点中最大的值



节点产生的顺序与结果有关: 可能导致不同的可被剪掉的节点数量

# Alpha-Beta 剪枝例子


$\alpha$  = 在当前路径上所有MAX节点中最大的值




节点产生的顺序与结果有关: 可能导致不同的可被剪掉的节点数量

# Alpha-Beta 举例


---



# Alpha-Beta 举例 2



# Alpha-Beta 举例 2




# Alpha-Beta 剪枝

假定修剪MIN节点子节点

- 假设正在计算节点  $n$  的 最小-值
- $n$  节点的值在检查其子节点的过程中逐渐减小
- 令  $\alpha$  是从根节点到当前MIN节点路径上的(任何一个)MAX节点所能取到的最大值
- 如果  $n$  的当前值比  $\alpha$  的小, 那么路径上的MAX分支节点将会避开这条路径, 所以我们可以剪掉(不去检查)  $n$  的其他子节点

对MAX节点子节点剪枝操作是对称的

- 令  $\beta$  是从根到当前MAX节点路径中的 MIN 节点所能达到的最小值



# Alpha-Beta 剪枝算法实现

```
def alpha-beta-search(state) return 一个行动
```

```
  v <- max-value(state,  $-\infty$ ,  $+\infty$ )
```

```
  return 导致值为 v 的行动
```

$\alpha$ : MAX节点的最大值, 当前路径上

$\beta$ : MIN节点的最小值, 当前路径上

```
def max-value(state,  $\alpha$ ,  $\beta$ ):
```

```
  if 终局-检测(state) return Utility(state)
```

```
    初始化  $v = -\infty$ 
```

```
    for each a in ACTIONS(state) do
```

```
       $v = \max(v, \min\text{-value}(\text{Result}(s,a),$   
         $\alpha, \beta))$ 
```

```
      if  $v \geq \beta$  return v
```

```
       $\alpha = \max(\alpha, v)$ 
```

```
    return v
```

```
def min-value(state,  $\alpha$ ,  $\beta$ ):
```

```
  if 终局-检测(state) return Utility(state)
```

```
    初始化  $v = +\infty$ 
```

```
    for each a in ACTIONS(state) do
```

```
       $v = \min(v, \max\text{-value}(\text{Result}(s,a),$   
         $\alpha, \beta))$ 
```

```
      if  $v \leq \alpha$  return v
```

```
       $\beta = \min(\beta, v)$ 
```

```
    return v
```



# Alpha-Beta 举例 2

$\alpha$ : MAX's best option on path to root

$\beta$ : MIN's best option on path to root

def max-value(state,  $\alpha$ ,  $\beta$ ):

    initialize  $v = -\infty$

    for each successor of state:


$v = \max(v, \text{value}(\text{successor}, \alpha, \beta))$

        if  $v \geq \beta$

            return  $v$

$\alpha = \max(\alpha, v)$

    return  $v$



# Alpha-Beta 举例 2

$\alpha$ : MAX's best option on path to root

$\beta$ : MIN's best option on path to root

def min-value(state,  $\alpha$ ,  $\beta$ ):

    initialize  $v = +\infty$

    for each successor of state:


$v = \min(v, \text{value}(\text{successor}, \alpha, \beta))$

        if  $v \leq \alpha$

            return  $v$

$\beta = \min(\beta, v)$

    return  $v$




# Alpha-Beta 剪枝属性

剪枝**不影响**根节点的最小最大值的计算！


好的子节点的排序能提高剪枝的有效性

假定是“完美的排序”：

- 时间复杂度能降到  $O(b^{m/2})$
- 搜索深度能提高一倍！



# 最小最大值 重新思考




把叶结点值当成准确值。



实际它们是不确定情况下的估计值，也许实际情况中，走b路径比走a更好。

# 不确定结果的游戏

---




# 搜索树中可能有机遇节点





井字游戏

最小最大值(Minimax)



投资游戏

期望最大值  
(Expectimax)



大富翁游戏

期望最小最大值(Expectiminimax)

# 最小最大值

Function 决策(s) returns 一个行动

return Actions(s) 中的行动 a ,它的  
value(Result(s,a)) 最大



function value(s) returns a value

If 终局-检测(s) then return Utility(s)

if Player(s) = MAX then return  $\max_{a \in \text{Actions}(s)} \text{value}(\text{Result}(s,a))$

if Player(s) = MIN then return  $\min_{a \in \text{Actions}(s)} \text{value}(\text{Result}(s,a))$

# 期望最小最大值(Expectiminimax)

Function 决策(s) returns 一个行动

return Actions(s) 里的一个行动 a,  
它的 value(Result(s,a)) 是最大的



function value(s) returns a value

if 终局-检测(s) then return Utility(s)

if Player(s) = MAX then return  $\max_{a \in \text{Actions}(s)} \text{value}(\text{Result}(s,a))$


if Player(s) = MIN then return  $\min_{a \in \text{Actions}(s)} \text{value}(\text{Result}(s,a))$

if Player(s) = CHANCE then return  $\sum_{a \in \text{Actions}(s)} \text{Pr}(a) * \text{value}(\text{Result}(s,a))$



# 概率 Probabilities

---





# 提示: 期望值

一个随机变量的期望值是概率分布到对应输出结果的加权平均值


举例: 去机场路上花费的时间?

时间:	20 min		30 min		60 min		
	x	+	x	+	x		
概率:	0.25		0.50		0.25		35 min



# 计算期望最小最大值的代码


$\text{sum}_{a \in \text{Action}(s)}$   
 $\text{Pr}(a) * \text{value}(\text{Result}(s,a))$



$$v = (1/2) (8) + (1/3) (24) + (1/6) (-12) = 10$$



# Expectimax Example

---



# Expectimax Pruning?

---



# 举例：十五子跳棋Backgammon

骰子增加了行动分支数  $b$ : 两个骰子有21 种不同的结果组合

- Backgammon  $\approx 20$  合法行动 ( $b=20$ )
- $b$  有时可能达到4000, 当两个骰子数相同时时候 (该游戏的一个规则)

当搜索深度增加, 走到一个给定的搜索节点的概率在变小


- 所以此时搜索的意义变小
- 因此限制搜索深度变得可行
- 但是剪枝变得比以前有所复杂...

历史上的人工智能程序: TDGammon 仅用步长为2的搜索 + 非常好的评估函数 + 增强学习法, 成就了世界冠军级的游戏水平。



Image: Wikipedia

# Utility值与决策的关系



$$x > y \Rightarrow f(x) > f(y)$$

$$f(x) = Ax + B \text{ where } A > 0$$

- 在最小最大值决策中，评估函数单调递增变化不影响决策结果
  - 只要好的状态结果有高的评估值
- 期望最小最大值，决策结果不受评估值的正仿射变换影响
  - 获胜概率高的状态，其对应的评估值也应该大

# 总结

---

博弈（游戏） 当找到最优解是不可能的时候，需要行动上的决策

- 限制深度搜索，和近似评估函数

博弈（游戏） 决策存在有效率的搜索计算

- **Alpha-beta** 剪枝

在博弈游戏上的探索产生了重要的研究思想

- 增强式学习 Reinforcement learning (国际跳棋)
- 迭代加深 Iterative deepening (国际象棋)
- 合理的元推理 Rational metareasoning (奥赛罗棋)
- 蒙特卡罗树搜索 Monte Carlo tree search (围棋)
- 经济学中关于部分信息可知的博弈方法 (纸牌)

视屏游戏中的决策问题，仍是巨大的挑战！（搜索空间庞大）

- $b = 10^{500}$ ,  $|S| = 10^{4000}$ ,  $m = 10,000$